

MONAI :Librería de Procesamiento de Imagen Médica

Autor: Emilio Delgado Muñoz







¿Qué es MONAI?

- Open-source framework
- Librería Python
- Software de Alta Calidad
- Repositorio de Modelos Preentrenados
- Software Development Kit (SDK)





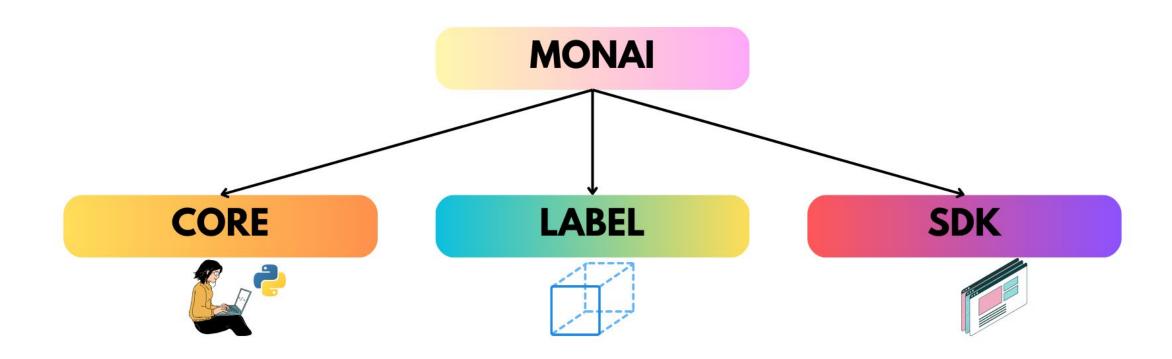
¿Cuáles son los beneficios de usa MONAI?

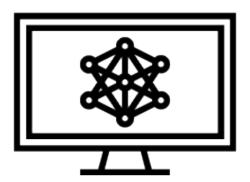
- **Diseño Open Source** (<u>Cualquiera puede</u> aportar)
- Estandarizado
- User Friendly (API Sencilla)
- Integración Sencilla con otros frameworks
- Reproducible





¿Qué puede ofrecernos MONAI?





Ventajas

- Carga y guardado de datos fácilmente para muchos estándares de imágenes médicas [NIFTI; DICOM; Numpy] (¡Solo preocúpate por las rutas de los archivos!)
- Gestión eficiente de la memoria (gestionada directamente por el framework)
- Muchos componentes específicos para el procesamiento de imágenes médicas
- Potente para crear pipelines de Deep Learning en imágenes médicas (funciones de pérdida, métricas y más, específicas del dominio)
- Contiene muchos conjuntos de datos de imágenes médicas (por ejemplo, MedNist, Decathlon y más)

Desventajas

1. API de alto nivel

Section Navigation

Applications

Auto3dseg

Federated Learning

Model Bundle

Transforms

Loss functions

Network architectures

Metrics

Optimizers

Data

Engines

Inference methods

Event handlers

Visualizations

Utilities

LossMetric

Mean Dice

Mean IoU

Generalized Dice Score

Area under the ROC curve

Confusion matrix

Hausdorff distance

Average surface distance

Surface dice

PanopticQualityMetric

Mean squared error

Mean absolute error

Root mean squared error

Peak signal to noise ratio

Structural similarity index

measure

Multi-scale structural similarity

index measure

Fréchet Inception Distance

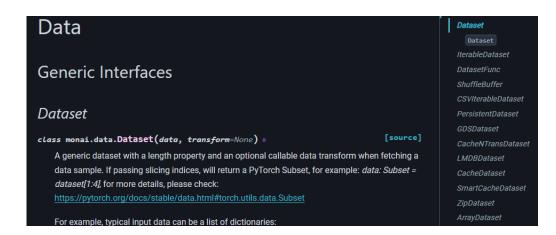
Maximum Mean Discrepancy

Cumulative average

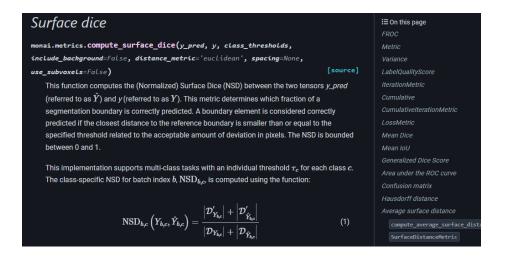


Data

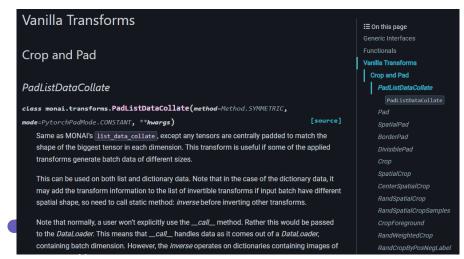
Monai Core



Metrics







Loss Functions







Easy Data Management API

Dataset

Dataset

IterableDataset

DatasetFunc

ShuffleBuffer

CSVIterableDataset

PersistentDataset

GDSDataset

CacheNTransDataset

LMDBDataset

CacheDataset

SmartCacheDataset

ZipDataset

ArrayDataset

ImageDataset

NPZDictItemDataset

CSVDataset

MONAI te permite adaptar la gestión de datos de forma sencilla para administrar eficientemente tus recursos:

- •¿Tienes poca RAM? Usa PersistentDataset o LMDBDataset.
- •¿Tienes más RAM disponible? Usa CacheDataset o SmartCacheDataset para mejorar la velocidad de las operaciones de entrada/salida durante el entrenamiento.



Arquitecturas codificada disponibles

```
SEResNet50
UNETR
                                                                                                     SEResNet101
                                                                                                     SEResNet152
class monai.networks.nets.UNETR(in_channels, out_channels, img_size,
                                                                                                     SEResNext50
feature size=16, hidden size=768, mlp dim=3072, num heads=12, pos embed='conv',
                                                                                                     SEResNext101
proj_type='conv', norm_name='instance', conv_block=True, res_block=True,
                                                                                                     HighResNet
                                                                                   [source]
dropout_rate=0.0, spatial_dims=3, qkv_bias=False, save_attn=False)
                                                                                                     DynUNet
   UNETR based on: "Hatamizadeh et al., UNETR: Transformers for 3D Medical Image Segmentation
                                                                                                     UNet
    <a href="https://arxiv.org/abs/2103.10504">https://arxiv.org/abs/2103.10504>"</a>
                                                                                                     AttentionUnet
    init (in_channels, out_channels, img_size, feature_size=16,
                                                                                                     UNETR
    hidden_size=768, mlp_dim=3072, num_heads=12, pos_embed='conv',
    proj_type='conv', norm_name='instance', conv_block=True, res_block=True,
                                                                                                     SwinUNETR
                                                                                                     BasicUNet
    dropout_rate=0.0, spatial_dims=3, qkv_bias=False, save_attn=False)
                                                                                   [source]
                                                                                                     BasicUNetPlusPlus
         Parameters:
                                                                                                     FlexibleUNet
             • in_channels - dimension of input channels.
                                                                                                     VNet
             • out_channels - dimension of output channels.
                                                                                                     RegUNet
             • img_size - dimension of input image.
                                                                                                     GlobalNet

    feature_size – dimension of network feature size. Defaults to 16.

                                                                                                     LocalNet
             • hidden_size - dimension of hidden layer. Defaults to 768.
                                                                                                     AutoEncoder
             • mlp_dim – dimension of feedforward layer. Defaults to 3072.
                                                                                                     VarAutoEncoder
             • num_heads - number of attention heads. Defaults to 12.
             • proj_type - patch embedding layer type. Defaults to "conv".
                                                                                                     ViTAutoEnc
```



Métodos de inferencia

MONAI ofrece múltiples métodos de inferencia basados en los enfoques de Split & Merge y Sliding Window.

Sliding Window Inference Function

monai.inferers.sliding_window_inference(inputs, roi_size, sw_batch_size, predictor, overlap=0.25, mode=BlendMode.CONSTANT, sigma_scale=0.125, padding_mode=PytorchPadMode.CONSTANT, cval=0.0, sw_device=None, device=None, progress=False, roi_weight_map=None, process_fn=None, buffer_steps=None, buffer_dim=-1, with_coord=False, *args, **kwargs) [source]

Sliding window inference on *inputs* with *predictor*.

The outputs of *predictor* could be a tensor, a tuple, or a dictionary of tensors. Each output in the tuple or dict value is allowed to have different resolutions with respect to the input. e.g., the input patch spatial size is [128,128,128], the output (a tuple of two patches) patch sizes could be ([128,64,256], [64,32,128]). In this case, the parameter *overlap* and *roi_size* need to be carefully chosen to ensure the output ROI is still an integer. If the predictor's input and output spatial sizes are not equal, we recommend choosing the parameters so that *overlap*roi_size*output_size/input_size* is an integer (for each spatial dimension).

When roi_size is larger than the inputs' spatial size, the input image are padded during inference. To maintain the same spatial sizes, the output image will be cropped to the original input size.

I≡ On this page
Inferers
Splitters
Mergers
Sliding Window Inference
Function

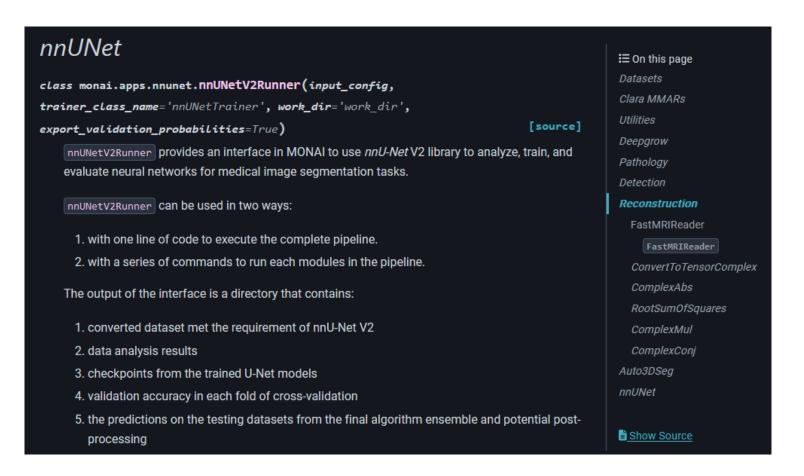
sliding_window_inference()

Show Source



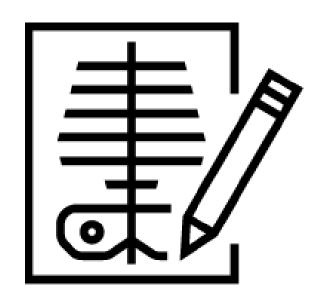
Runners

MONAI define el concepto de "Runners". Un Runner es un pipeline compleo para segmentar conjuntos de datos de imágenes médicas.









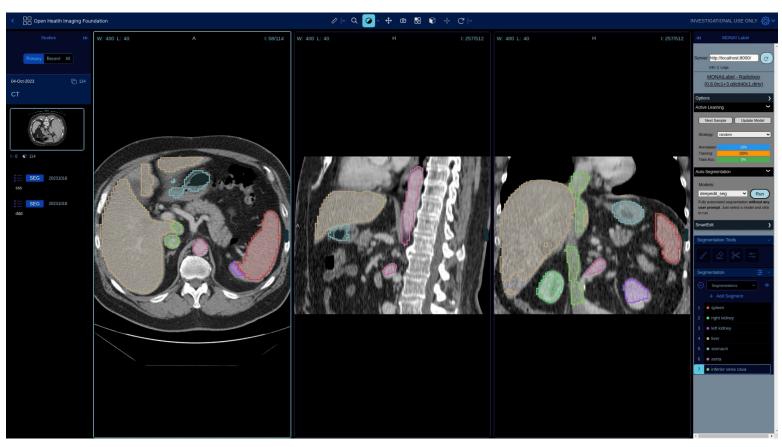


MONAI define **MONAI Label** como:

"Una herramienta inteligente de etiquetado y aprendizaje de imágenes que utiliza asistencia por IA para reducir el tiempo y esfuerzo necesarios para anotar nuevos conjuntos de datos. A través de la interacción con el usuario, MONAI Label entrena o utiliza un modelo de IA para una tarea específica y lo actualiza continuamente a medida que recibe nuevas imágenes anotadas."



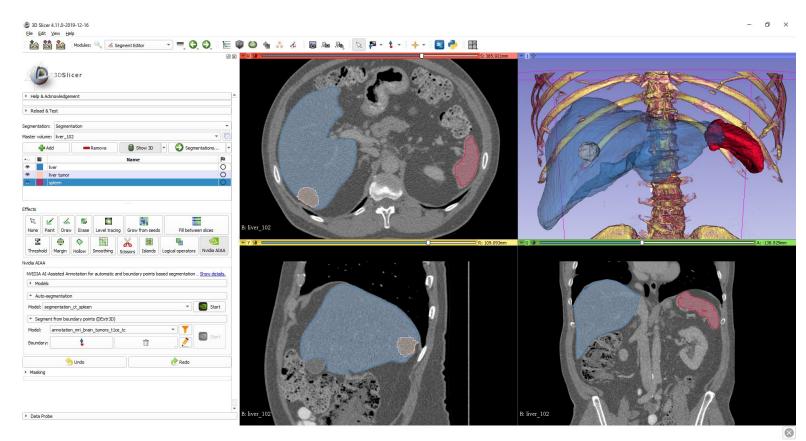
OHIF Viewer (Monai Open Source Viewer)



Source: https://github.com/Project-MONAI/MONAILabel/tree/main/plugins/ohifv3



3D Slicer Viewer



Source: https://www.slicer.org/





o —

o —



MONAI define **MONAI SDK** (o **MONAI Deploy**) como:

"MONAI Deploy aspira a convertirse en el estándar de facto para desarrollar, empaquetar, probar, desplegar y ejecutar aplicaciones de IA médica en entornos clínicos. MONAI Deploy establece un conjunto de pasos intermedios donde investigadores y médicos pueden ganar confianza en las técnicas y enfoques utilizados con IA, permitiendo así un flujo de trabajo iterativo."



MONAI SDK fue diseñado con los siguientes cuatro objetivos fundamentales:

- **Usabilidad**: Proporciona una API intuitiva para estructurar el código como un flujo de trabajo, es decir, como un grafo dirigido de operadores.
- **Composición**: Ofrece una colección de operadores como bloques de construcción para abordar tareas comunes en el ámbito sanitario.
- **Portabilidad**: Permite empaquetar la aplicación, los modelos asociados y los metadatos relevantes en un paquete autocontenido y fácil de trasladar entre entornos.
- **Preparación para producción**: Está diseñado para ejecutar aplicaciones en distintos entornos, desde el desarrollo hasta su uso en producción clínica.

Diagrama de Arquitectura

Development-Time Run-Time package App Packager **Application** makes use of creates **MONAl App Package** Graph executed by contains **App Runner** Operator

Concepts

Development-Time Inference = inference application in the healthcare domain

Graph = Serie of operators (Transforms or Operations) [See Monai Core]

Run-Time = Use of final application

Source: https://docs.monai.io/projects/monaideploy-app-

sdk/en/stable/introduction/architecture.html



Monai Generative Models

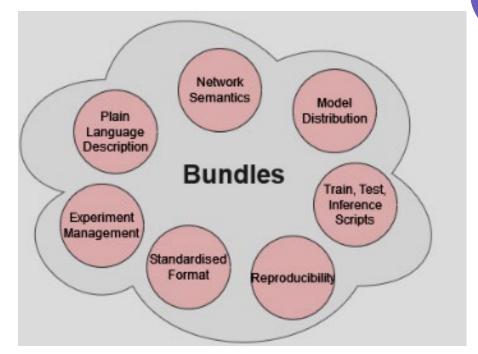


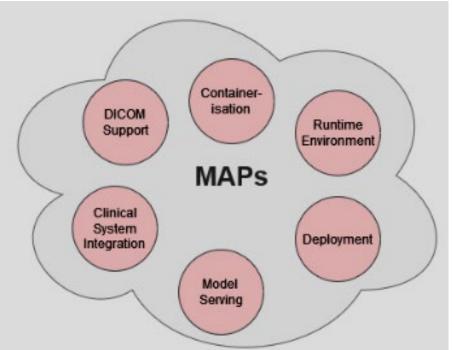
MONAI Model Zoo



Bundle vs. MAPs

- •Bundle: Es una forma de distribuir modelos entrenados con MONAI junto con sus metadatos, código, documentación y otros recursos, todo ello siguiendo una especificación y una estructura de archivos definida.
- •MAP (Model Application Package): Se centra en la despliegue, contenedorización, integración con sistemas clínicos existentes y otras áreas clave para poner los modelos en uso real en entornos clínicos.





What is Model ZOO?

MONAI Model Zoo es un repositorio de modelos preentrenados en formato bundle

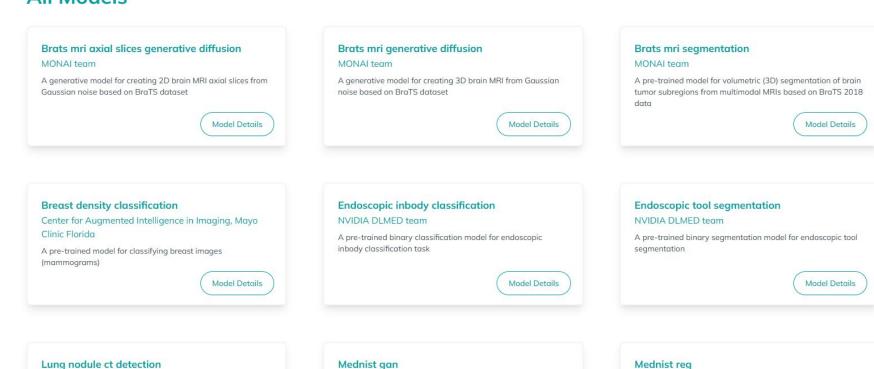
All Models

MONAl team

A pre-trained model for volumetric (3D) detection of the lung

Model Details

lesion from CT image on LUNA16 dataset



This example of a GAN generator produces hand xray images

Model Details

MONAl team

hand xray image registration

This is an example of a ResNet and spatial transformer for

MONAl Team

like those in the MedNIST dataset

Model Details

What is Model ZOO?

Lung nodule ct detection

Download

Model Metadata:

Overview: A pre-trained model for volumetric (3D) detection of the lung lesion from CT image on LUNA16 dataset

Author(s): MONAI team

References:

Lin, Tsung-Yi, et al. 'Focal loss for dense object detection. ICCV 2017

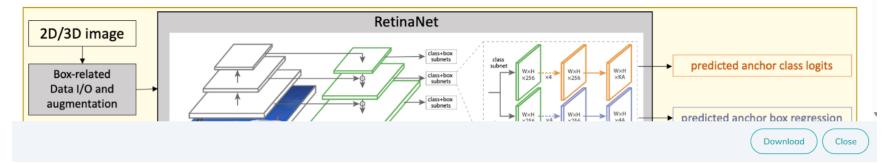
Downloads: 2079 File Size: 148.1MB Version: 0.5.9

Model README:

Model Overview

A pre-trained model for volumetric (3D) detection of the lung nodule from CT image.

This model is trained on LUNA16 dataset (https://luna16.grand-challenge.org/Home/), using the RetinaNet (Lin, Tsung-Yi, et al. "Focal loss for dense object detection." ICCV 2017. https://arxiv.org/abs/1708.02002).



×

What is Model ZOO?

MONAI Bundle Commands

In addition to the Pythonic APIs, a few command line interfaces (CLI) are provided to interact with the bundle. The CLI supports flexible use cases, such as overriding configs at runtime and predefining arguments in a file.

For more details usage instructions, visit the MONAI Bundle Configuration Page.

Execute training:

```
python -m monai.bundle run --config_file configs/train.json
```

Please note that if the default dataset path is not modified with the actual path in the bundle config files, you can also override it by using --dataset_dir :

```
python -m monai.bundle run --config_file configs/train.json --dataset_dir <actual dataset path>
```

Override the train config to execute evaluation with the trained model:

```
python -m monai.bundle run --config_file "['configs/train.json','configs/evaluate.json']"
```

Execute inference on resampled LUNA16 images by setting "whether raw luna16": false in inference.json:

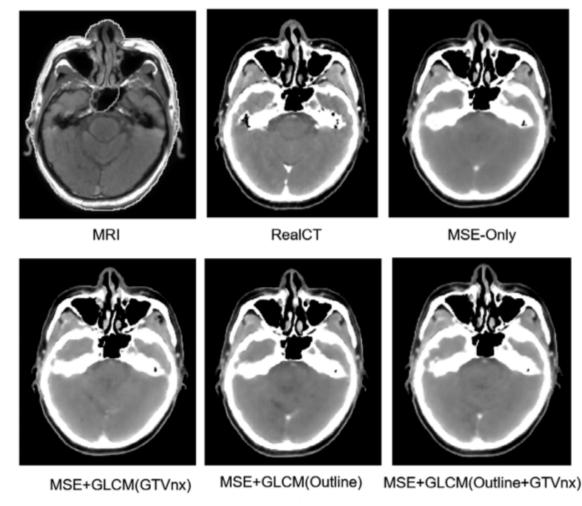
```
\verb|python -m monai.bundle run --config_file configs/inference.json|\\
```

With the same command, we can execute inference on original LUNA16 images by setting "whether_raw_luna16": true in inference.json . Remember to also set "data_list_file_path": "\$@bundle_root + '/LUNA16_datasplit/mhd_original/dataset_fold0.json'" and change "dataset_dir" .

Monai Generative Models

MONAI incorporará **modelos generativos** que podrán utilizarse en tareas como:

- Síntesis de imágenes
- Transferencia de dominio
- Reconstrucción de imágenes por RMN (MRI)
- Detección de anomalías



Source: https://aapm.onlinelibrary.wiley.com/doi/full/10.1002/mp.16850

Código



https://github.com/emi-dm/Medical-Image-PGTD



Recursos útiles

- https://monai.io/
- https://github.com/Project-MONAI/tutorials
- https://www.youtube.com/playlist?list=PLtoSVSQ2XzyCobzE6NvwjNpITsQyPUtfs
- https://colab.research.google.com/drive/1x8VjJXpkK7aYVrzt2l3eaYs9ewpHDaJr?usp=sharing (Keras 3.0 integration with Monai)
- https://github.com/Project-
 MONAI/tutorials/blob/main/modules/3d_image_transforms.ipynb

¿Alguna pregunta?

